



Pontificia Universidad  
**JAVERIANA**  
Bogotá

[VIGILADA MINEDUCACIÓN]

# Reducción de la dimensionalidad ANÁLISIS DE COMPONENTES PRINCIPALES




Pontificia Universidad  
**JAVERIANA**  
Colombia

# La Maldición de la Dimensionalidad

**Muchas variables implican un crecimiento exponencial de los datos necesarios para obtener resultados significativos porque la información queda dispersa en el hiperespacio.**

# Reduccion de dimensionalidad



# Tomando una foto



# Tomando una foto










# Reduccion de dimensionalidad






# Reduccion de dimensionalidad



# Reduccion de dimensionalidad



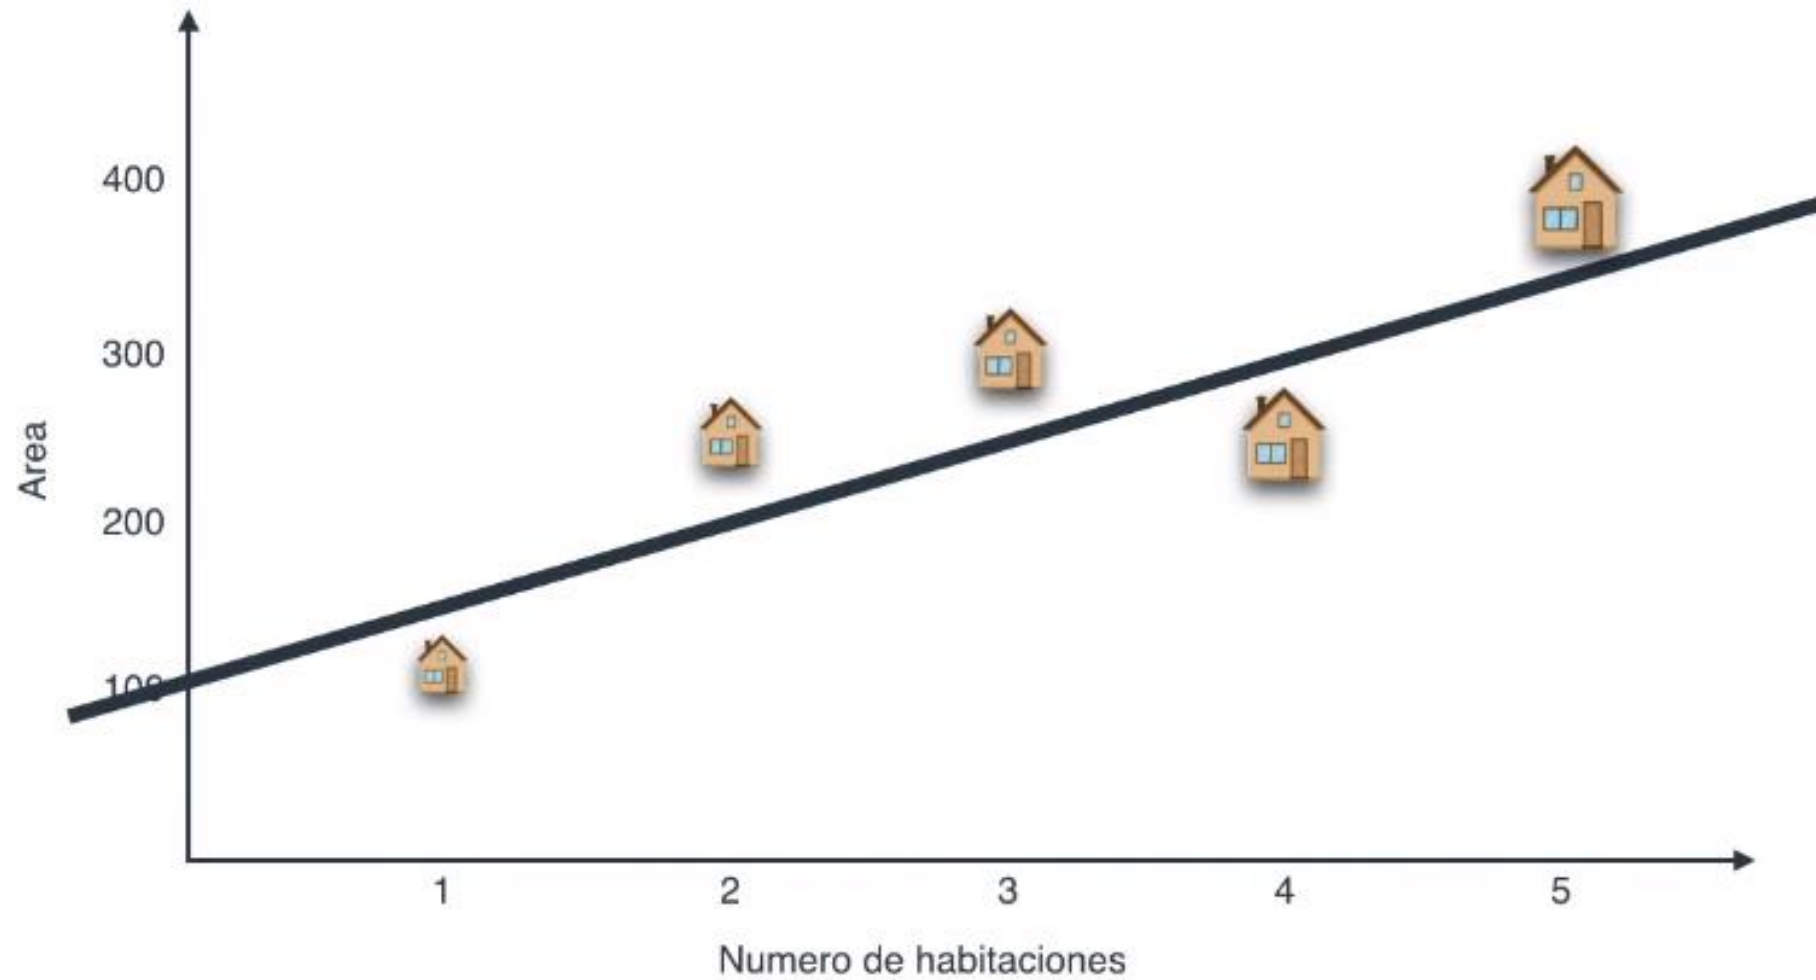
# Datos de casas

Area  
Numero de habitaciones  
Numero de baños  
Escuelas cercanas  
Crimen en el area

# Datos de casas











2 dimensiones

area  
numero de habitaciones



1 dimension

tamaño



Reducción de la dimensionalidad  
Análisis de Componentes Principales

# Datos de casas

## 5 dimensiones

Area

Numero de habitaciones

Numero de baños

Escuelas cercanas  
crimen en el area


## 2 dimensions

Tamaño

Ubicación

# Promedio, varianza, covarianza


# Promedio



# Varianza



$$\text{Varianza} = \frac{1^2 + 0^2 + 1^2}{3} = 2/3$$




$$\text{Varianza} = \frac{5^2 + 0^2 + 5^2}{3} = 50/3$$

# Varianza?



# Varianza?







# Varianza?



# Varianza?




$$\text{x-varianza} = \frac{2^2 + 0^2 + 2^2}{3} = 8/3$$

$$\text{y-varianza} = \frac{1^2 + 0^2 + 1^2}{3} = 2/3$$




# Covarianza




# Covarianza


Producto  
de las  
coordenadas



# Covarianza




$$\text{covarianza} = \frac{(-2) + 0 + (-2)}{3} = -4/3$$




$$\text{covarianza} = \frac{2 + 0 + 2}{3} = 4/3$$

# Covarianza



# Covarianza





# Covarianza



covarianza  
negativa




covarianza cero  
(o muy pequeña)




covarianza  
positiva

# Valores y vectores propios (eigenvalues and eigenvectors)



# Matriz de covarianza



# Transformaciones lineales

$$\begin{pmatrix} 9 & 4 \\ 4 & 3 \end{pmatrix}$$


# Transformaciones lineales

The diagram illustrates a linear transformation between two 2D coordinate systems. On the left, a coordinate system with horizontal and vertical axes is shown. An arrow points from this system to a matrix representation of the transformation. Below the matrix, another arrow points to the transformation equation. A second coordinate system is shown on the right, representing the transformed space.

$$\begin{pmatrix} 9 & 4 \\ 4 & 3 \end{pmatrix}$$
$$(x, y) \longrightarrow (9x+4y, 4x+3y)$$




# Transformaciones lineales







# Transformaciones lineales




# Transformaciones lineales



# Transformaciones lineales



# Transformaciones lineales




Vectores propios  
(dirección)

$$\begin{pmatrix} 2 \\ 1 \end{pmatrix} \quad \begin{pmatrix} -1 \\ 2 \end{pmatrix}$$

Valores propios  
(magnitud)

$$11 \quad 1$$



# Valores y vectores propios

$$\begin{pmatrix} 9 & 4 \\ 4 & 3 \end{pmatrix} \mathbf{v} = \lambda \mathbf{v}$$

Diagram illustrating the eigenvalue equation for a 2x2 matrix. The matrix is  $\begin{pmatrix} 9 & 4 \\ 4 & 3 \end{pmatrix}$ . The vector  $\mathbf{v}$  is labeled "Vector propio" (Eigenvector). The scalar  $\lambda$  is labeled "Valor propio" (Eigenvalue).

# Valores propios

$$\begin{pmatrix} 9 & 4 \\ 4 & 3 \end{pmatrix}$$

Polinomio característico

$$\begin{vmatrix} x-9 & -4 \\ -4 & x-3 \end{vmatrix} = (x-9)(x-3) - (-4)(-4) = x^2 - 12x + 11 \\ = (x-11)(x-1)$$

Valores propios **11** y **1**

# Vectores propios


$$\begin{pmatrix} 9 & 4 \\ 4 & 3 \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix} = 11 \begin{pmatrix} u \\ v \end{pmatrix}$$

$$\begin{pmatrix} u \\ v \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$$

$$\begin{pmatrix} 9 & 4 \\ 4 & 3 \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix} = 1 \begin{pmatrix} u \\ v \end{pmatrix}$$

$$\begin{pmatrix} u \\ v \end{pmatrix} = \begin{pmatrix} -1 \\ 2 \end{pmatrix}$$

# Análisis de componentes principales (PCA)



$$\Sigma = \begin{pmatrix} 9 & 4 \\ 4 & 3 \end{pmatrix}$$

$$\begin{pmatrix} 2 \\ 1 \end{pmatrix}$$

11

$$\begin{pmatrix} -1 \\ 2 \end{pmatrix}$$


1

Vectores propios  
(dirección)


Valores propios  
(magnitud)



# Análisis de componentes principales (PCA)



# Análisis de componentes principales (PCA)



# PCA

Tabla grande

X1	X2	X3	X4	X5
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*


Matriz de covarianza

$$\begin{pmatrix} * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \end{pmatrix}$$

Vectores y valores propios

$V_1$   $\lambda_1$   
 $V_2$   $\lambda_2$   
 $V_3$   $\lambda_3$   
 $V_4$   $\lambda_4$   
 $V_5$   $\lambda_5$

Grande  
 ↑  
 Pequeño



# PCA

Tabla grande

X1	X2	X3	X4	X5
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*
*	*	*	*	*

Matriz de covarianza

$$\begin{pmatrix} * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \end{pmatrix}$$

Vectores y valores propios


$V_1$   $\lambda_1$   
 $V_2$   $\lambda_2$

Grande

Pequeño

Tabla pequeña

W1	W2
*	*
*	*
*	*
*	*
*	*
*	*
*	*
*	*
*	*
*	*
*	*
*	*
*	*
*	*



# Transformación de variables

Variable 1	Variable 2	Variable 3	Variable 4	Variable 5	Variable 6




Comp. 1	Comp. 2	Comp. 3	Comp. 4	Comp. 5	Comp. 6

- Los primeros componentes reúnen la mayor cantidad de varianza de los datos originales.
- Los componentes son combinaciones lineales de las variables originales.

$$Comp_1 = w_{11}Var_1 + w_{12}Var_2 + \dots + w_{1n}Var_n$$



# Conceptos




## Análisis Factorial

El objetivo es develar la estructura de los datos. El fin último generalmente es detectar redundancia de variables (o casos) y, si se desea, realizar reducción de variables independientes (o casos). Otro posible objetivo es detectar factores latentes.






# Análisis Factorial Vs Componentes Principales




**EFA:** Variables observadas son combinaciones lineales de los factores latentes.



**PCA:** Los componentes son combinaciones lineales de las variables observadas.



# Análisis Factorial



## Objetivo:

- Determinar factores latentes a las variables observadas
- Disminución de dimensiones

## Técnica de extracción:

- Componentes principales
- Mínimos cuadrados: entre matriz de correlación y matriz reproducida
- Máxima verosimilitud: supuesto de normalidad multivariada

## Rotación:

Se rotan los factores latentes para mejorar su interpretación.

# Supuestos



## Correlación Lineal

- Las Relaciones que se prueban únicamente son lineales
- Pueden utilizarse otro tipo de coeficientes de correlación



## Naturaleza de las variables

- Deben ser variables escalares pero puede adaptarse para variables ordinales



## Factorabilidad


- Existe correlación entre las variables
- Colinealidad. KMO, Barlett



## Tamaño de muestra

- $N/k > 20:1$

# Rotación de ejes




## Rotaciones: Varimax - Quartimax


Original

	Factor 1	Factor 2
Variable 1	0.5	0.4
Variable 2	-0.2	0.5
Variable 3	0.3	0.4
Variable 4	0.6	0.2

Varimax




	Factor 1	Factor 2
Variable 1	0.8	0.4
Variable 2	-0.2	0.3
Variable 3	0.3	0.9
Variable 4	0.9	0.2



Quartimax

	Factor 1	Factor 2
Variable 1	0.6	0.2
Variable 2	-0.1	0.6
Variable 3	0.2	0.65
Variable 4	0.7	0.05



Las cargas factoriales no son representativas de valores verdaderos, solo ilustrativas del concepto

# Data Understanding/Preparation



- **Estandarizar variables**
  - Vuelve comparables las magnitudes de las variables
- **Análisis de correlaciones**
  - Permite darse una idea de la estructura de correlación en los datos
  - Da cierta forma válida la pertinencia de la reducción de dimensiones
  - Puede hacerse sobre:
    - ✓ **Mapa de calor de matriz de correlaciones/covarianzas:** debe percibirse cierta correlación entre las variables
    - ✓ **Prueba de esfericidad de Barlett:** contrasta la hipótesis de que la matriz de covarianzas es la matriz identidad
    - ✓ **KMO:** Compara correlaciones vs las correlaciones parciales. Regla del pulgar  $KMO > 0.5$

# Aplicaciones de PCA/EFA



- **Reducción de dimensiones**
  - Volver escalables algunos algoritmos aplicados dentro de Analítica
- **Identificar factores latentes**
  - Aplicados usualmente dentro del campo de la psicología
  - A través de información “indirecta” ayudan, de cierta manera, a la medición de variables que no se pueden observar directamente: felicidad, inteligencia, satisfacción, etc.
  - Permite mejorar la comprensión de grandes volúmenes de variables
  - Puede apoyar técnicas de clustering